

在校生人数データ自動収集システム

ご報告資料 2026年4月11日

現在手作業で行っている「各大学・専門学校の在校生人数データの収集・転記作業」を自動化するシステムの設計を進めています。本資料では、調査結果・技術方針・ご確認いただきたい事項をまとめます。

1. 現状の確認

いただいたExcelファイル（専門学校分）を分析した結果は以下のとおりです。

項目	数値
専門学校の対象校数	2,212校
対象法人数	1,442法人
対象都道府県	47
学科別データ行数	約9,761件
2025年度の採録済み（○）	943校（43%）
2025年度の部分採録（△）	804校（36%）
未採録・対象外等	465校（21%）

※ 大学約700校分のデータについては、別途サンプルデータのご提供をお願いいたします。

2. 自動化の方針

ご依頼の工程への対応

ご依頼の工程	自動化内容
工程1：PDFの収集	各校のウェブサイトからPDFを自動で発見・ダウンロード
工程2：年度チェック	前年度データとの自動比較により令和8年度版かを判定
工程3：データ転記	PDFからデータを自動抽出し、データベースに格納
工程4：競合校レポート更新	週次で自動集計し、Excelファイルを生成

段階的アプローチ

一度に全自動化を目指すのではなく、段階的に自動化率を高めます。

段階	内容	期間	自動化率
第0段階	200校のサンプルで検証	2週間	—
第1段階	各校のURL特定＋PDF発見	2～3週間	70～85%
第2段階	テキスト型PDFのデータ抽出	2～3週間	60～80%
第3段階	画像型PDF対応＋学科変更対応	継続	+10～15%
第4段階	週次の定期更新運用	1週間	—

6月の公開開始までに第2段階まで完了を目指します。

人手が残る部分

完全自動化が難しい箇所は、システム内の「確認キュー」に入り、担当者が画面上で確認・修正します。ご指示の通り、学科変更が発生した場合はシステム側でエラーを出し、人力で対応する方針とします。

- ・自動で判定できなかった学校のURL確認（推定220～440校）
- ・画像のみのPDFの確認
- ・学科の新設・廃止・改称・統合の対応（推定100～300件）

推定作業量：6～8月の期間中、週2～4時間程度

NotebookLM等との比較

ご提案のNotebookLM等にPDFを投入する方法も検討しました。今回は毎年繰り返す定型作業のため、構造化パイプラインの方が適しています。

観点	NotebookLM等	構造化パイプライン（今回）
毎年の繰り返し	毎回手動投入が必要	一度構築すれば自動で回る
週次の増分更新	困難	自動で差分検知・更新
数値の正確性	回答にブレの可能性	ルールベースで安定
監査・追跡	難しい	全データの出典PDFを記録

※ NotebookLMは「過去データの横断分析・質問応答」には有効です。データベース構築後の補助ツールとして活用する余地があります。

3. 初期検証の結果

設計に先立ち、50校のサンプルで技術検証を実施しました。結果は想定以上に良好です。

検証項目	目標	実測値	判定
学校URL発見率（50校テスト）	95%以上	100%（86%が高確信度）	達成

検証項目	目標	実測値	判定
文科省学校コード照合率	85%以上	91% (2,014/2,212校)	達成
PDFテキスト抽出可否	80%以上	100% (4校全てテキスト型)	達成
競合分類の自動マッチ率	80%以上	85% (精確一致)	達成

※ 大学のPDFフォーマットは専門学校と異なることが判明しました。v1では専門学校に集中し、大学は別途対応することを推奨します。

4. ご確認いただきたい事項

確認済み：学科変更時の取り扱い

ご指示に従い、学科の統合・分割・新設・廃止等が発生した場合はシステムがエラーを出力し、人力で対応する方針とします。

確認済み：学校の識別方法

文部科学省の「学校コード」を利用します。検証の結果、2,212校中2,014校（91%）が自動照合可能であることを確認しました。残り198校は初回のみ手動で対応付けを行います。

確認済み：大学の取り扱い

検証の結果、大学のPDFフォーマットは専門学校と異なることが判明しました。v1では専門学校（2,071校）に集中し、大学（773校）は別途対応とします。

以下の3点について、ご判断・ご確認をお願いいたします。

確認事項1：対象校の範囲

Excel上に「学校なし」「閉校」「統合」「対象外」と記載されている学校（計155校）は、自動収集の対象から除外してよろしいでしょうか。（除外後の対象校数：2,057校）

確認事項2：競合校レポートの分野分類

「競合校の在校生数」ファイルでは15の分野カテゴリ（ゲーム、IT、マンガ・アニメ等）に分類されていますが、この分類ルール（どの学科名がどの分野に該当するか）を明文化する必要があります。検証では85%が自動分類可能でしたが、残り15%の判断基準をお教えいただけますか。

確認事項3：運用体制

- ・確認作業（週2～4時間）は、アルバイトの方が担当する想定でよろしいでしょうか。
- ・システムの設置先は、学内PC（Linux）とクラウドのどちらが望ましいでしょうか。
- ・Google検索APIの利用（各校の公開ページ発見のため）について、学内方針上の制約はありますか。

5. 想定されるリスク

リスク	影響	対策
学校サイトがPDFを遅れて公開	収集漏れ	週次で自動再チェック
画像のみのPDFが多い場合	OCR精度低下	該当校は確認キューで人手対応
学校サイトのアクセス制限	PDF取得不可	ブラウザ自動化で対応
学科の大幅な改組	自動対応困難	エラー出力＋人力対応（ご指示済み）

6. 次のステップ

1. 上記の確認事項についてご判断をいただく
2. （大学分のサンプルデータをいただく）
3. 第0段階（200校サンプル検証）を開始
4. 2週間後に検証結果をご報告

以上